



MAESTRÍA EN CIENCIA DE DATOS

INGENIERIA DE DATOS

Taller 1: Flujos de Datos Tipo Batch

Instrucciones: Implementar un flujo etl que tenga 4 fuentes de datos, por ejemplo, CSV, MySQL, PostgreSQL, MongoDB, etc En el flujo se implementará la transformación de los datos, utilizando nodos de Knime: Diseñar el DW respectivo utilizando un modelo estrella con al menos 5 dimensiones y una tabla de hechos.

Dataset

Utilice un dataset de Kaggle, llamado: International football results from 1872 to 2026, el cual contiene información sobre partidos internacionales de futbol masculinos. Contiene los siguientes archivos 4 archivos csv, con datos.

results.csv	date- fecha del partido	shootouts.csv	date- fecha del partido
	home_team- el nombre del equipo local		home_team- el nombre del equipo local
	away_team- el nombre del equipo visitante		away_team- el nombre del equipo visitante
	home_score- Marcador final del equipo local, incluyendo la prórroga, sin incluir la tanda de penaltis.		winner- ganador de la tanda de penaltis
	away_score- Resultado final del equipo visitante, incluyendo la prórroga, sin incluir la tanda de penaltis.		first_shooter- el equipo que tiró primero en la tanda de penaltis
	tournament- el nombre del torneo		
	city- el nombre de la ciudad/pueblo/unidad administrativa donde se jugó el partido		
	country- el nombre del país donde se jugó el partido		

	neutral- Columna VERDADERO/FALSO que indica si el partido se jugó en una sede neutral.		
--	--	--	--

goalscorers.csv	date- fecha del partid	former_names.csv	
	home_team- el nombre del equipo local		former- nombre anterior utilizado por dicho equipo
	away_team- el nombre del equipo visitante		start_date- fecha de inicio del uso del nombre anterior
	team- nombre del equipo que marcó el gol		end_date- fecha de finalización del uso del nombre anterior
	scorer- nombre del jugador que marcó el gol		current- Nombre del equipo tal como se usa actualmente (o el apellido si el equipo ya no existe)
	own_goal- si el gol fue un autogol		
	penalty- si el gol fue penalti		

Contenedor

El contenedor se configuro de la misma manera para el servicio de MongoDB que en clase, se realizaron cambios en los servicios de MySQL y PostgreSQL para que el contenedor tuviera acceso a los datos csv, para poder cargarlos mediante script a tablas de las DB sin errores o conflictos por no encontrar el archivo en el directorio o restricción de seguridad. Las modificaciones se encuentran en *dockers.txt*

Fuentes de datos

Tal como es requerido se utilizaron 4 fuentes de datos, simuladas de la siguiente manera:

1. Archivo CSV: se cargo directamente los datos mediante un bloque de KNIME los datos de former_names.csv
2. MongoDB: se agregan los datos de shootouts.csv a una base local de MongoDB y utilizando un bloque de la extensión de KNIME para MongoDB se realizo la conexión. Se realizo una conversión de los datos tipo JSON a Tabla para poder ser explorados y realizar procesos de transformación necesarios.
3. MySQL: se agregaron los datos utilizando un script (*script_mysql.txt*) en el cual se creó una tabla llamada goalscorers.
 - a. Debido a los valores nulos presentados en la columna *minute* se realizo en la inserción de datos una conversión de valores NA a NULL.
 - b. En los datos de las columnas penalty y own_goal, se realizó una conversión de 1/0 a True/False por la convención de un dato de tipo binario.
4. PostgreSQL: se agregaron datos mediante script (*script_postgress.txt*) en una tabla llamada results, no se realizo ninguna modificación mas que el manejo de NA con NULL.

Flujo ETL

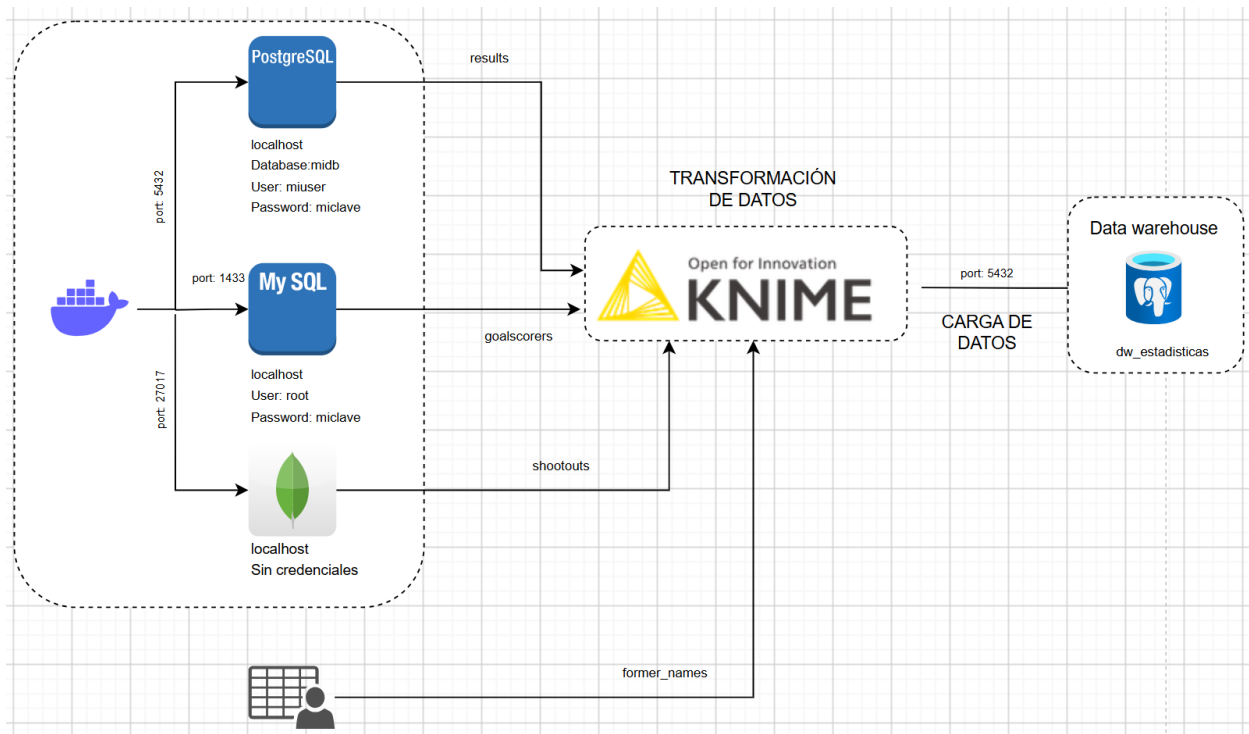


Ilustración 1. Diagrama de flujo ETL implementado

En KNIME se realizó el flujo ETL con los siguientes puntos relevantes que comentar

- Extracción: Se utilizaron los bloques de KNIME para conexión a DB, Mongo y archivos CSV para llevar los datos.
- Transformación: Se realizaron transformaciones básicas de tipo de datos y manejo de datos nulos:
 - Se realizó el tratamiento de valores nulos en los datos de goalscorers, ya que algunas filas no tenían el nombre de goleador, valores que fueron reemplazados con "Desconocido". Igual otros casos que no tenían información sobre si hubo o no penal, los cuales fueron rellenos con false, ya que eran un número mínimo (<0.5%) de los datos.
- Carga: Se realizó la carga de datos en dimensiones y tabla de hechos para la creación de un DW en PostgreSQL llamado dw_estadisticas.

Modelo Estrella

Para el modelo se definió como granularidad de la tabla de hechos que cada fila represente un partido de fútbol,




Ilustración 2. Modelo Estrella

Datos de Tabla de hechos

Fuente principal: *results.csv*, se utiliza fecha, equipo local, equipo visitante, torneo, ciudad, país, goles locales y goles visitantes.

Se utiliza *goalscorers.csv* para tener información complementaria como cantidad de goles de penal o cantidad de autogoles, no se utiliza el nombre del goleador, debido a la granularidad de la tabla de hecho que es por partido y en el caso de goalscorers su granularidad es fila por gol.

También se utilizó la información de *shootouts.csv*, que registra tanda de penales para definir un partido, se lo utilizó como información agregada como si en el partido hubo una tanda de penales y el ganador.

En este caso no se utilizó los datos de *former_names.csv*, ya que en este caso no se relacionaron los nombres históricos con el nombre actual de naciones, ya que para la estadística puede ser más relevante que aparezcan tal y cual su nombre histórico.

Mejoras futuras al DW

Se podría crear otra dimensión con información de goalscorer.csv, la dimensión jugador, pero al tener una tabla de hechos con una granularidad de fila por partido, se requiere asociar todos los jugadores a un partido utilizando un id.

Se podría también crear una segunda tabla de hechos con una granularidad diferente, fila por gol, en el este caso se podría incorporar nombres de goleadores, minutos de goles, o si fue autogol,